Sesión 1 : Estadística Básica

Daniel Fuertes Oscar Moreno Marc Torres

11 de noviembre de 2026

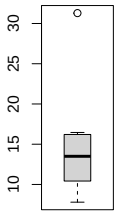
1. Calcular la media, la mediana, la desviación tipo, el primer cuartil, el tercer cuartil, el rango intercuartílico y dibujar el correspondiente boxplot de la muestra de datos.

$$x = (7,80,\ 8,25,\ 12,60,\ 13,50,\ 15,96,\ 16,46,\ 31,29)$$

$$\bar{x} = \frac{1}{7}\sum_{i=1}^{7} x_i = 15,12\ ; \qquad s = \sqrt{\frac{1}{6}\sum_{i=1}^{7}(x_i - \bar{x})^2} = 7,89$$

$$x_{(4)} = 13,50\ ; \qquad Q_1 = x_{(2)} = 8,25\ ; \qquad Q_3 = x_{(6)} = 16,46$$

$$\text{RIC} = Q_3 - Q_1 = 8,21$$



2. Justificar que la media de una muestra escogida al azar es un estimador más fiable que la media de una muestra de expertos.

Dada una muestra de observaciones escogidas al azar, independientes e idénticamente distribuidas $X_1, \ldots, X_n$, es decir que todo el mundo sabe más o menos mismo de la variable de estudio X que es aleatoria, suponiendo que la esperanza (media poblacional) es finita[1], $\mu = E[X] < \infty$, y que para todo i, $E[X] = E[X_i] = \mu$, por la *Ley fuerte de los grandes números* sabemos que

$$P\Big(\lim_{n\to\infty} \overline{X}_n = \mu\Big) = 1$$

es decir, que la probabilidad de que la media muestral converge a μ es 1. No garantiza que para todo $n' > n$, $\overline{X}_{n'}$ sea mas cercana a μ pero si con un n' lo suficientemente grande. Una muestra no escogida al azar de m expertos $X_1, \ldots, X_m$ no es representativa, su media muestral $\overline{X}_m$ puede no converger a μ en m infinito. En la práctica $m \ll n$ pues siempre hay mucha más gente que expertos en cualquier tema, entonces són más fiables las medias de las muestras al azar para un n suficientemente grande.

[1] Alternativamente, la varianza es finita y por la ley débil de los grandes números converge en probabilidad.

3. Suponga la variable aleatoria “tiempo que tardo en ir de mi casa al trabajo” y diferencie factores sistemáticos y factores aleatorios intervinientes en su medición

Sea T el tiempo, una observación es

$$t_i = \mu + \varepsilon_i$$

donde μ es el factor sistemático, aquel predecible y que desplaza de forma regular el tiempo observado. Por ejemplo, si viajo en autobús, salgo a la hora punta, y empiezo el cronómetro en la puerta, el tiempo suele ser mayor que si viajara en coche, fuera de madrugada y empezara a contar en el portal. Los aleatorios ϵ_i cambian de un trayecto a otro y su efecto no se puede conocer de antemano, como por ejemplo, los retrasos derivados de la meteorología, una variación del tráfico por un accidente o encontrarse con alguien que detenga el viaje. En distintas mediciones pueden aumentar o reducir el tiempo.

4. Cuando podemos asegurar que el mecanismo generador de una variable aleatoria se aproxima a una distribución gaussiana.

Cuando una variable es la suma de muchos efectos aleatorios independientes ε_i , con varianzas finitas e igualmente irrelevantes para explicar la misma. En este caso, su distribución tiende a aproximarse a una distribución normal/gaussiana, por el Teorema Central del Límite.

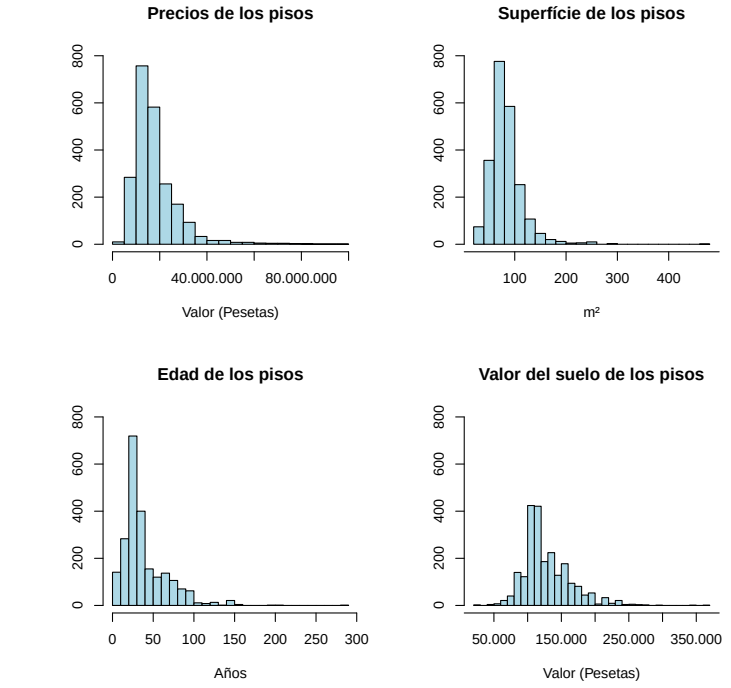
5. Efectúe un summary de las variables de `bcn_pisos.txt`. Detecte si en el fichero proporcionado hay registros duplicados y elimínelos.

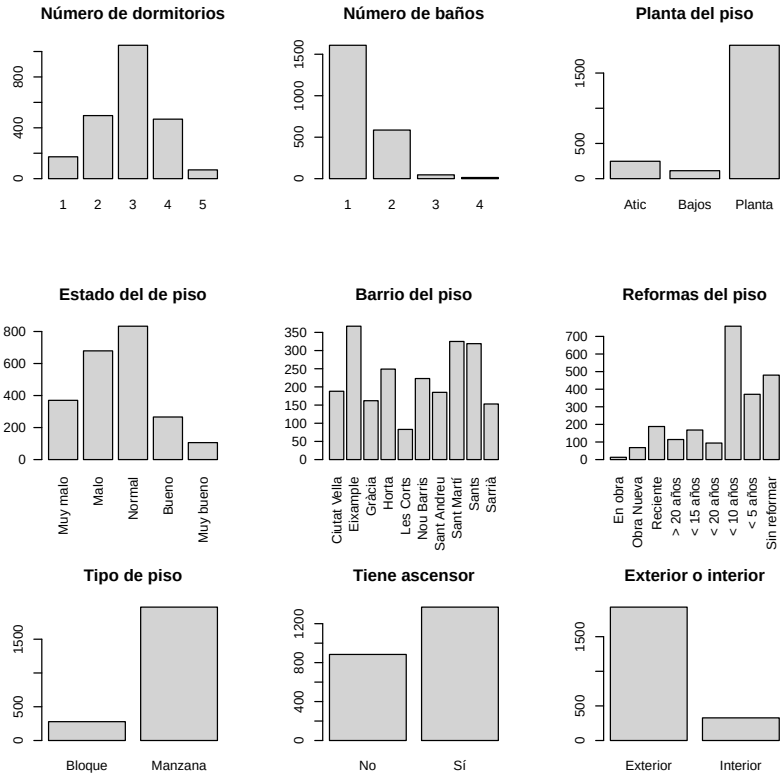
```
> summary(pisos)
    Valor              Superf            Dorm           Banys
 Min.   : 3007368   Min.   : 23.24   Min.   :1.000   Min.   :1.000
 1st Qu.:12025000   1st Qu.: 64.20   1st Qu.:2.000   1st Qu.:1.000
 Median :15456000   Median : 78.54   Median :3.000   Median :1.000
 Mean   :17823727   Mean   : 83.97   Mean   :2.903   Mean   :1.319
 3rd Qu.:20920248   3rd Qu.: 95.00   3rd Qu.:3.000   3rd Qu.:2.000
 Max.   :99662144   Max.   :475.30   Max.   :5.000   Max.   :4.000

      Edat          Estat         Planta                Dist          ValSol
 Min.   :  0.00   1_MM:395   Atic  : 255   Eixample    :385   Min.   :
    20321
 1st Qu.: 25.00   2_M :692   Bajos : 119   Sant_Marti  :335   1st Qu
    .:106679
 Median : 30.00   3_N :856   Planta:1955   Sants       :329   Median
    :119965
 Mean   : 40.75   4_B :277                 Horta       :252   Mean
    :128708
 3rd Qu.: 50.00   5_MB:109                 Nou_Barris  :234   3rd Qu
    .:146537
 Max.   :289.00                            Ciutat_Vella:192   Max.
    :365754
                                           (Other)     :602
  Tipus       Ascens     ExtInt           Reforma
 BLOQ: 282   NO: 920   EXT:1991   REF1A5     :778
 MANZ:2047   SI:1409   INT: 338   SINREFORMA:501
                                  REF5A10    :378
                                  RECIENREF  :197
                                  REF10-15   :182
                                  REF>20     :115
                                  (Other)    :178
> pisos <- pisos[!duplicated(pisos), ]
```

Hemos sabido que hay duplicados porque el que tomó los datos duplicó registros para hinchar la base de datos. En concreto, había 43 duplicados.

6. Represente gráficamente la distribución de cada variable del fichero: histograma o función de densidad para las variables continuas o diagrama de barras para las variables categóricas.





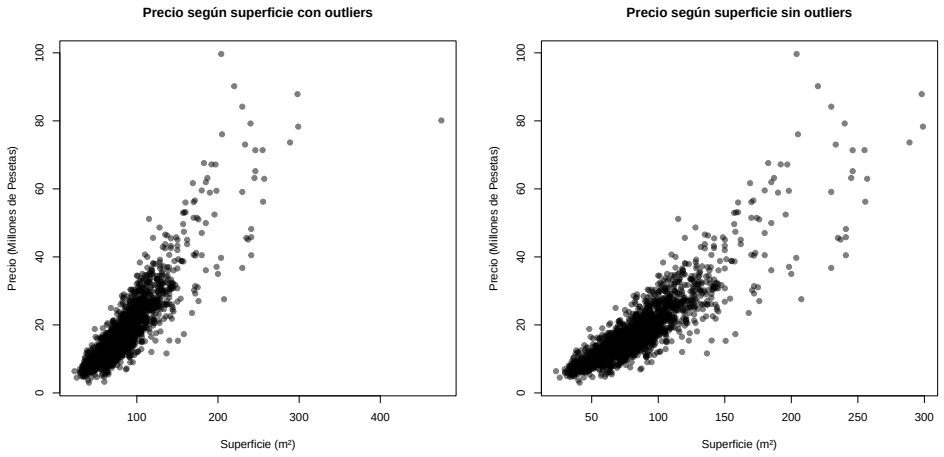
7. Identifique si existe algún piso que podemos considerar "outlier" (para ello solo tenga en cuenta las variables continuas). Elimínelo del data frame

Usamos la función *Local Outlier Factor* de la librería *DescTools* con $k = 5$ sobre las variables contínuas del dataframe pisos.

```
> outliers.scores <- LOF(scale(pisos_cont), k = 5)
> outlier <- order(outlier.scores, decreasing=T)[1:10]
> cbind(outlier.scores[outliers], pisos_cont[outliers,])
     outlier.scores[outliers]    Valor Superf Edat    ValSol
163                  9.731024  3283200  60.00   198  80107.40
112                  5.966654 80126080 475.30   289 166465.75
162                  2.972040  8450000  65.00   150 100036.25
1787                 2.646105  6908846  86.63    10  20320.85
409                  2.590744 67587904 182.67    60 345825.40
1732                 2.450899 23520000 168.00    35  66821.50
116                  2.383793  7321600  51.20   150  80107.40
1995                 2.306762  7170080  87.44    35  26963.80
1139                 2.287689 38354208 103.66    50 292681.80
1987                 2.265198  6300000  63.00    53  46892.65
```

Viendo estos valores de *scores*, descartamos los dos primeros, donde podemos ver que su edad es muy elevada, o edad y valor para lo que se esperaría de un piso pequeño. Quizás se trate de pisos históricos con alto valor cultural.

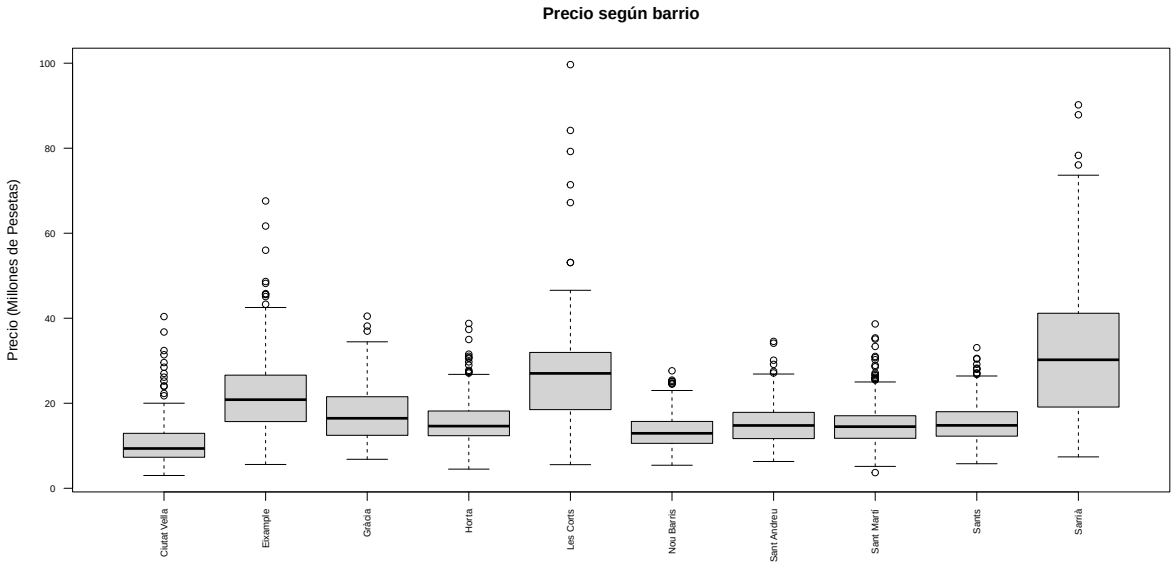
8. Efectúe un diagrama bivariante (plot) entre el "Valor de los pisos" y su "Superficie". Calcule la covariancia y la correlación entre ambas variables.




```
> cov(pisos_cont_so$Valor, pisos_cont_so$Superf)
[1] 269332201
> cor(pisos_cont_so$Valor, pisos_cont_so$Superf)
[1] 0.884583
```

Con una covarianza positiva, podemos decir que según incrementa la superfície, incrementa el valor. Con una correlación cercana a 1, decimos que existe una asociación estadística significativa entre ambas variables.

9. Calcule la asociación entre el "Valor de los pisos" y el "Distrito".



Al ser una variable categórica y otra contínua, el test que hay que hacer para determinar la independencia de las variables es la F de *Fisher*.

$$\begin{cases} H_0 : \text{Valor y Dist son independientes} \\ H_1 : \text{Valor y Dist no son independientes} \end{cases}$$

```
> oneway.test(pisos_so$Valor ~ pisos_so$Dist, var.equal = TRUE)

        One-way analysis of means

data:  pisos_so$Valor and pisos_so$Dist
F = 121.97, num df = 9, denom df = 2242, p-value < 2.2e-16
```

Con el *p-value* tan pequeño, hay que descartar la hipótesis nula H_0 y aceptar que el distrito y el valor de los pisos están relacionados.

10. Calcule la asociación entre el “Distrito” y el “Estado de la vivienda”.

Distrito	Muy malo	Malo	Normal	Bueno	Muy bueno	N_j (f_j)
Ciutat Vella	74	52	45	9	6	186 (0.08)
Eixample	76	119	119	35	18	367 (0.16)
Gràcia	36	49	49	23	5	162 (0.07)
Horta	24	68	110	34	13	249 (0.11)
Les Corts	4	26	36	11	6	83 (0.04)
Nou Barris	29	77	94	17	6	223 (0.10)
Sant Andreu	19	53	84	19	10	185 (0.08)
Sant Martí	45	89	119	55	17	325 (0.14)
Sants	42	95	121	41	20	319 (0.14)
Sarrià	19	51	56	22	5	153 (0.07)
N_i (f_i)	368 (0.16)	679 (0.30)	833 (0.37)	266 (0.12)	106 (0.05)	2251 (1.00)

Con una variable categórica nominal y una categórica ordinal, hemos visto la tabla de contingencia, vamos a aplicar el test estadístico sobre las hipótesis

$$\begin{cases} H_0 : \text{Dist y Estat son independientes} \\ H_1 : \text{Dist y Estat no son independientes} \end{cases}$$

```
> chisq.test(pisos_so$Dist, pisos_so$Estat)

        Pearson's Chi-squared test

data:  pisos_so$Dist and pisos_so$Estat
X-squared = 151.29, df = 36, p-value = 4.407e-16
```

El p-value es muy pequeño, por lo que tenemos que rechazar la hipótesis nula y aceptar que el estado de la vivienda y el distrito tienen una relación estadísticamente significativa.